

Desenvolvimento e Avaliação de Modelos de Machine Learning para Detecção de Doença Arterial Coronariana: Explicabilidade e Análise de Erros de Classificação

Ana Clara Gierse Raymundo ¹ Erica Gonçalves de Oliveira ¹
Luana Domingos Branco ¹ Victor Luiz de Sá Alves ¹
Luiz Carlos Machi Lozano ^{1,2}

¹Faculdade de Computação e Informática (FCI)
Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil

²Programa de Pós-Graduação em Computação Aplicada
Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil

<10428453,10428547,10428459,10426310@mackenzista.com.br>
<luiz.lozano@mackenzie.br>

2026

Resumo

As doenças cardiovasculares constituem uma das principais causas de mortalidade no mundo, sendo a doença arterial coronariana uma de suas manifestações de maior relevância clínica. Este projeto propõe o desenvolvimento e a avaliação de modelos supervisionados de Machine Learning para auxiliar na detecção da presença de doença arterial coronariana a partir de dados clínicos. Será utilizado o conjunto Z-Alizadeh Sani, disponibilizado pelo UCI Machine Learning Repository, composto por 303 pacientes e 54 características relacionadas a informações demográficas, fatores de risco, sinais, sintomas e resultados de exames clínicos. Serão avaliados os algoritmos Regressão Logística, Support Vector Machine, Random Forest e XGBoost, com ajuste de hiperparâmetros por meio do GridSearchCV. O desempenho será comparado utilizando acurácia, precisão, recall, especificidade, F1-score e ROC-AUC, com atenção especial ao recall e aos falsos negativos. Também serão investigadas a importância das variáveis e a explicabilidade das classificações. Espera-se identificar uma abordagem com bom equilíbrio entre desempenho, capacidade de identificação dos pacientes com a doença e interpretabilidade dos resultados.

Palavras-chave: Doença Arterial Coronariana; Machine Learning; Dados Clínicos; Classificação; Explicabilidade.

Abstract

Cardiovascular diseases are among the leading causes of mortality worldwide, and coronary artery disease is one of their most clinically relevant manifestations. This project proposes the development and evaluation of supervised Machine Learning models to assist in detecting coronary artery disease using clinical data. The Z-Alizadeh Sani dataset, available from the UCI Machine Learning Repository, will be used. It contains records from 303 patients and 54 features related to demographic information, risk factors, signs, symptoms, and clinical examinations. Logistic Regression, Support Vector Machine, Random Forest, and XGBoost will be evaluated, with hyperparameter optimization performed using GridSearchCV. Model performance will be compared using accuracy, precision, recall, specificity, F1-score, and ROC-AUC, with particular attention to recall and false-negative cases. Feature importance and model explainability will also be investigated. The expected result is to identify an approach that achieves an appropriate balance between predictive performance, detection of patients with coronary artery disease, and interpretability of the classifications.

Keywords: Coronary Artery Disease; Machine Learning; Clinical Data; Classification; Explainability.

1 Introdução

1.1 Contextualização

As doenças cardiovasculares constituem um dos principais problemas de saúde pública em âmbito mundial. Segundo a Organização Mundial da Saúde, elas estão entre as principais causas globais de mortalidade e incluem condições como doença coronariana, doenças cerebrovasculares e outras enfermidades que afetam o coração e os vasos sanguíneos ([World Health Organization, 2025](#)).

Entre essas condições encontra-se a doença arterial coronariana (DAC), também denominada *Coronary Artery Disease* (CAD). A doença está associada à redução do fluxo sanguíneo para o músculo cardíaco em razão do estreitamento das artérias coronárias, frequentemente relacionado ao processo de aterosclerose, caracterizado pelo acúmulo de placas nas paredes arteriais ([National Heart, Lung, and Blood Institute, 2025](#)).

A investigação da doença arterial coronariana pode envolver informações relacionadas aos fatores de risco, sinais e sintomas, exames laboratoriais, eletrocardiográficos, ecocardiográficos e exames de imagem. Nesse cenário, técnicas de Machine Learning vêm sendo estudadas como ferramentas capazes de analisar simultaneamente diferentes características clínicas e identificar padrões associados a doenças cardiovasculares ([SADR et al., 2024](#); [ISLAM et al., 2024](#)).

Estudos recentes empregam diferentes algoritmos para tarefas relacionadas à classificação de doenças cardíacas, incluindo Regressão Logística, Support Vector Machine, Random Forest, Decision Tree e XGBoost. Os resultados apresentados na literatura indicam que o desempenho pode variar de acordo com o conjunto de dados, as características utilizadas, o pré-processamento e a metodologia adotada para treinamento e validação ([ISLAM et al., 2024](#); [EL-SOFANY, 2024](#)).

1.2 Justificativa

A escolha da doença arterial coronariana está relacionada à sua relevância no contexto das doenças cardiovasculares e à possibilidade de aplicação de técnicas de Machine Learning a dados clínicos relacionados à sua identificação ([World Health Organization, 2025](#); [ALIZADEHSANI et al., 2013](#)).

Para o desenvolvimento do projeto foi escolhido o conjunto Z-Alizadeh Sani, disponibilizado pelo UCI Machine Learning Repository e desenvolvido especificamente para estudos relacionados à doença arterial coronariana ([ALIZADEHSANI; ROSHANZAMIR; SANI, 2013](#)). A base reúne características clínicas de diferentes naturezas, permitindo avaliar tanto o desempenho dos classificadores quanto a contribuição das variáveis para as decisões dos modelos ([ALIZADEHSANI et al., 2013](#)).

Estudos mostram que o pré-processamento, a seleção de características e o ajuste dos modelos podem influenciar o desempenho de classificadores aplicados à predição de doenças cardíacas ([ISLAM et al., 2024](#); [MANIKANDAN et al., 2024](#)).

Neste projeto, será dada atenção especial aos falsos negativos. Um falso negativo ocorre quando um paciente pertencente à classe CAD é classificado como Normal; por esse motivo, o recall será analisado em conjunto com acurácia, precisão, especificidade, F1-score e ROC-AUC.

1.3 Objetivo

O objetivo geral deste projeto é desenvolver e avaliar modelos supervisionados de Machine Learning para auxiliar na detecção da presença de doença arterial coronariana a partir de dados clínicos.

Como objetivos específicos, pretende-se realizar a análise exploratória e a preparação do conjunto de dados Z-Alizadeh Sani, implementar os algoritmos Regressão Logística, Support Vector Machine, Random Forest e XGBoost, otimizar seus hiperparâmetros, comparar seus desempenhos utilizando diferentes métricas, analisar os erros de classificação e investigar quais características apresentam maior influência nas decisões dos modelos.

1.4 Opção do Projeto

O projeto se enquadra na **Opção Framework**, conforme proposta da disciplina, utilizando técnicas de aprendizado supervisionado para um problema de classificação binária na área da saúde.

O desenvolvimento será realizado em Python, utilizando principalmente o framework `scikit-learn` para as etapas de preparação dos dados, divisão entre treino e teste, validação cruzada, otimização de hiperparâmetros e implementação dos modelos Regressão Logística, Support Vector Machine e Random Forest. Para o modelo XGBoost, será utilizada a biblioteca específica `XGBoost`, integrada ao mesmo fluxo de treinamento e avaliação.

A partir das características clínicas disponíveis no conjunto de dados, os modelos deverão classificar os pacientes entre duas categorias: CAD, correspondente à presença de doença arterial coronariana, e Normal. Essa formulação é compatível com a finalidade do conjunto Z-Alizadeh Sani, disponibilizado pelo UCI Machine Learning Repository para tarefas de classificação relacionadas à doença arterial coronariana ([ALIZADEHSANI; ROSHANZAMIR; SANI, 2013](#)).

1.5 Descrição do Problema

O problema investigado consiste em verificar se modelos supervisionados de Machine Learning são capazes de distinguir pacientes com e sem doença arterial coronariana utilizando as características clínicas presentes no conjunto Z-Alizadeh Sani.

Na base utilizada, o paciente é classificado como CAD quando apresenta estreitamento igual ou superior a 50% no diâmetro de pelo menos uma das artérias coronárias consideradas na avaliação. Caso contrário, é classificado como Normal ([ALIZADEHSANI; ROSHANZAMIR; SANI, 2013](#); [ALIZADEHSANI et al., 2013](#)).

Dessa forma, as características dos pacientes serão utilizadas como variáveis de entrada, enquanto a classificação CAD ou Normal será considerada a variável-alvo. A questão central do projeto consiste em verificar qual dos modelos avaliados apresenta melhor equilíbrio entre desempenho global, capacidade de identificar corretamente os pacientes com a doença e possibilidade de interpretar as decisões realizadas.

A comparação não será realizada exclusivamente pela acurácia. Serão avaliadas também precisão, recall, especificidade, F1-score, ROC-AUC e a matriz de confusão, permitindo observar separadamente os diferentes tipos de acertos e erros produzidos por cada modelo.

2 Referencial Teórico

A aplicação de Machine Learning na área da saúde tem sido investigada como uma forma de identificar padrões presentes em dados clínicos e apoiar tarefas de classificação. Em estudos relacionados a doenças cardiovasculares, diferentes algoritmos vêm sendo utilizados para analisar fatores de risco, sintomas e resultados de exames ([SADR et al., 2024](#); [RAO; MUNEESWARI, 2024](#)).

Entre os modelos frequentemente empregados encontra-se a Regressão Logística, que apresenta estrutura relativamente simples e maior facilidade de interpretação. O Support Vector Machine busca estabelecer uma fronteira capaz de separar as classes no espaço de características. Random Forest combina múltiplas árvores de decisão, enquanto XGBoost utiliza uma estratégia de *boosting* baseada em árvores sequenciais. Esses algoritmos aparecem com frequência em estudos de classificação de doenças cardíacas ([ISLAM et al., 2024](#); [EL-SOFANY, 2024](#)).

A preparação dos dados e a escolha das características também exercem influência sobre o desempenho dos modelos. Islam et al. ([ISLAM et al., 2024](#)) avaliaram diversos algoritmos em diferentes conjuntos de dados e analisaram técnicas de seleção e extração de características. Manikandan et al. ([MANIKANDAN et al., 2024](#)) compararam classificadores com e sem o uso da técnica Boruta para seleção de atributos e observaram alterações no desempenho dos modelos após a seleção das características.

O ajuste dos hiperparâmetros também constitui uma etapa importante. Rasheed et al. ([RASHEED et al., 2024](#)) utilizaram GridSearchCV para otimização de classificadores aplicados a dados de doença cardíaca, combinando o ajuste dos parâmetros com técnicas de validação.

Além do desempenho, a interpretabilidade dos modelos tem recebido atenção crescente. El-Sofany et al. ([EL-SOFANY; BOUALLEGUE; EL-LATIF, 2024](#)) aplicaram técnicas de Inteligência Artificial Explicável, incluindo SHAP, para analisar a contribuição

das características para previsões relacionadas a doença cardíaca. Essa abordagem permite complementar as métricas tradicionais com informações sobre os fatores que influenciaram as classificações.

No caso específico da doença arterial coronariana, o conjunto Z-Alizadeh Sani foi desenvolvido para permitir a investigação de técnicas computacionais aplicadas à identificação da doença. Alizadehsani et al. ([ALIZADEHSANI et al., 2013](#)) utilizaram informações clínicas associadas à angiografia coronariana para estudar métodos de mineração de dados voltados à classificação de CAD.

Dessa forma, este projeto parte de abordagens já exploradas na literatura, mas direciona a análise para a comparação de quatro algoritmos, considerando simultaneamente desempenho, falsos negativos, importância das características e explicabilidade.

3 Metodologia

Este trabalho caracteriza-se como uma pesquisa aplicada, quantitativa e experimental. O desenvolvimento será realizado em Python, utilizando bibliotecas voltadas à análise de dados, visualização e Machine Learning. O processo compreenderá a análise do conjunto de dados, sua preparação, o treinamento dos modelos, a otimização dos hiperparâmetros e a avaliação dos resultados.

3.1 Aspectos Éticos do Uso da Inteligência Artificial e Responsabilidade

O projeto utilizará exclusivamente o conjunto Z-Alizadeh Sani, disponibilizado publicamente pelo UCI Machine Learning Repository, sem coleta direta de informações de pacientes ([ALIZADEHSANI; ROSHANZAMIR; SANI, 2013](#)).

Os modelos desenvolvidos terão finalidade acadêmica e experimental e não serão considerados instrumentos de diagnóstico. Como o conjunto contém 303 pacientes provenientes de um contexto clínico específico, os resultados obtidos não serão interpretados como evidência de generalização para outras populações ([ALIZADEHSANI; ROSHANZAMIR; SANI, 2013](#); [ALIZADEHSANI et al., 2013](#)).

A interpretabilidade também será considerada durante a avaliação dos modelos. Técnicas de Inteligência Artificial Explicável, como SHAP, vêm sendo utilizadas para investigar a contribuição das características nas previsões de modelos aplicados a doenças cardíacas ([EL-SOFANY; BOUALLEGUE; EL-LATIF, 2024](#)).

Dessa forma, os resultados serão tratados como evidências experimentais restritas à base analisada, e qualquer aplicação clínica exigiria validação adicional.

3.2 Resultados da Análise Exploratória

A análise exploratória permitiu verificar a estrutura e a qualidade inicial do conjunto de dados. Foram analisados 303 registros, sem identificação de valores ausentes ou registros duplicados.

A variável-alvo *Cath* apresentou 216 pacientes classificados como CAD e 87 como Normal, correspondendo a aproximadamente 71,3% e 28,7% da amostra, respectivamente, conforme apresentado na Figura 1.




Figura 1 – Distribuição dos pacientes segundo a variável-alvo *Cath*.
Fonte: Elaborado pelos autores (2026).

Também foram analisados diabetes mellitus, hipertensão, tabagismo atual e obesidade em relação às classes CAD e Normal. Para as características numéricas, foi construída uma matriz de correlação envolvendo idade, índice de massa corporal, pressão arterial, frequência de pulso, glicemia de jejum, triglicerídeos, LDL, HDL e fração de ejeção.

Essas análises tiveram caráter exploratório e serão utilizadas para orientar as etapas posteriores de preparação e modelagem.

3.3 Metodologia Proposta

Serão avaliados quatro algoritmos supervisionados: Regressão Logística, Support Vector Machine, Random Forest e XGBoost. Esses algoritmos são utilizados em estudos de classificação de doenças cardíacas e permitem comparar abordagens com diferentes estratégias de aprendizagem (ISLAM et al., 2024; SADR et al., 2024).

Os hiperparâmetros serão ajustados por meio do *GridSearchCV*, associado à validação cruzada estratificada. O uso dessa estratégia para otimização de classificadores em problemas relacionados à doença cardíaca também foi empregado por Rasheed et al. (RASHEED et al., 2024).

A avaliação será realizada por meio de acurácia, precisão, recall, especificidade, F1-score, ROC-AUC e matriz de confusão. O recall da classe CAD receberá atenção especial devido ao foco do projeto na redução de falsos negativos.

Também serão analisadas as características com maior influência sobre as classificações. Para complementar as medidas de importância dos modelos, poderá ser utilizada a técnica SHAP, já empregada em estudos de explicabilidade aplicados à predição de doenças cardíacas (EL-SOFANY; BOUALLEGUE; EL-LATIF, 2024).

Por fim, os registros classificados incorretamente serão analisados para identificar possíveis padrões entre falsos positivos e falsos negativos.

4 Resultados e Discussão

4.1 Resultados da Análise Exploratória

A análise exploratória permitiu verificar inicialmente a estrutura e a qualidade do conjunto de dados utilizado. O arquivo analisado contém 303 registros e não apresen-

tou valores ausentes ou registros duplicados, o que reduz a necessidade de intervenções relacionadas à imputação ou remoção de registros nesta etapa.

A distribuição da variável-alvo *Cath* apresentou diferença entre as duas classes. Dos 303 pacientes analisados, 216 foram classificados como CAD e 87 como Normal. Dessa forma, aproximadamente 71,3% da amostra corresponde à classe CAD e 28,7% à classe Normal.

Essa diferença na distribuição será considerada durante as etapas de treinamento e avaliação dos modelos, pois a proporção entre as classes pode influenciar o comportamento dos classificadores.

A análise também contemplou alguns fatores de risco categóricos, incluindo diabetes mellitus, hipertensão, tabagismo atual e obesidade. Esses fatores foram comparados visualmente entre os grupos CAD e Normal, com o objetivo de observar possíveis diferenças de distribuição entre os pacientes.

Para as características numéricas, foi construída uma matriz de correlação incluindo variáveis como idade, índice de massa corporal, pressão arterial, frequência de pulso, glicemia de jejum, triglicerídeos, LDL, HDL e fração de ejeção. A análise teve caráter exploratório e não foi utilizada, nesta etapa, para estabelecer relações causais ou determinar a importância preditiva das variáveis.

Os resultados obtidos na análise exploratória serão utilizados como apoio para as próximas etapas de preparação dos dados e construção dos modelos de Machine Learning.

4.2 Resultados Esperados

Espera-se comparar o desempenho da Regressão Logística, Support Vector Machine, Random Forest e XGBoost na classificação dos pacientes entre CAD e Normal.

Os modelos serão avaliados considerando acurácia, precisão, recall, especificidade, F1-score e ROC-AUC, sem estabelecer previamente qual algoritmo deverá apresentar o melhor resultado.

Também se espera identificar as características que mais contribuem para as classificações e analisar os padrões associados aos falsos positivos e falsos negativos. Estudos anteriores indicam que a seleção e a análise das características são relevantes na construção de modelos de classificação de doenças cardíacas ([ISLAM et al., 2024](#); [MANIKANDAN et al., 2024](#)).

Dessa forma, a comparação final considerará desempenho, erros de classificação e interpretabilidade.

5 Conclusão

Este projeto propõe o desenvolvimento e a avaliação de modelos supervisionados de Machine Learning para auxiliar na classificação da presença de doença arterial coronariana utilizando o conjunto Z-Alizadeh Sani.

A análise exploratória já permitiu verificar a estrutura dos dados, a ausência de valores ausentes e registros duplicados e a distribuição entre as classes CAD e Normal. As próximas etapas compreenderão a preparação dos dados, o treinamento e a comparação dos quatro classificadores definidos.

A avaliação considerará diferentes métricas, análise dos erros e explicabilidade, com atenção especial aos falsos negativos.

Como o projeto ainda está em desenvolvimento, não é possível antecipar qual modelo apresentará o melhor desempenho. Os resultados terão finalidade exclusivamente acadêmica e serão interpretados dentro das características e limitações do conjunto de dados utilizado.

Referências

ALIZADEHSANI, R. et al. A data mining approach for diagnosis of coronary artery disease. *Computer Methods and Programs in Biomedicine*, v. 111, n. 1, p. 52–61, 2013.

ALIZADEHSANI, R.; ROSHANZAMIR, M.; SANI, Z. *Z-Alizadeh Sani*. 2013. UCI Machine Learning Repository. Acesso em: 12 set. 2026. Disponível em: <https://archive.ics.uci.edu/dataset/412/z+alizadeh+sani>.

EL-SOFANY, H.; BOUALLEGUE, B.; EL-LATIF, Y. M. A. A proposed technique for predicting heart disease using machine learning algorithms and an explainable ai method. *Scientific Reports*, v. 14, p. 23277, 2024.

EL-SOFANY, H. F. Predicting heart diseases using machine learning and different data classification techniques. *IEEE Access*, v. 12, p. 106146–106160, 2024.

ISLAM, M. A. et al. Precision healthcare: A deep dive into machine learning algorithms and feature selection strategies for accurate heart disease prediction. *Computers in Biology and Medicine*, v. 176, p. 108432, 2024.

MANIKANDAN, G. et al. Classification models combined with boruta feature selection for heart disease prediction. *Informatics in Medicine Unlocked*, v. 44, p. 101442, 2024.

National Heart, Lung, and Blood Institute. *Coronary Heart Disease: What Is Coronary Heart Disease?* 2025. Acesso em: 12 set. 2026. Disponível em: <https://www.nhlbi.nih.gov/health/coronary-heart-disease>.

RAO, G. S.; MUNEESEWARI, G. A review: Machine learning and data mining approaches for cardiovascular disease diagnosis and prediction. *EAI Endorsed Transactions on Pervasive Health and Technology*, v. 10, 2024.

RASHEED, S. et al. Heart disease prediction using gridsearchcv and random forest. *EAI Endorsed Transactions on Pervasive Health and Technology*, v. 10, 2024. Disponível em: <https://publications.eai.eu/index.php/phat/article/view/5523>.

SADR, H. et al. Cardiovascular disease diagnosis: a holistic approach using the integration of machine learning and deep learning models. *European Journal of Medical Research*, v. 29, p. 455, 2024.

World Health Organization. *Cardiovascular diseases (CVDs)*. 2025. Acesso em: 12 set. 2026. Disponível em: [https://www.who.int/news-room/fact-sheets/detail/cardiovascular-diseases-\(cvds\)](https://www.who.int/news-room/fact-sheets/detail/cardiovascular-diseases-(cvds)).